



ITAM  
Departamento de Estadística

Inferencia Estadística– Laboratorio #7  
Estimador de Máxima Verosimilitud y Convergencia



Otoño 2021

1. Define el estimador de máxima verosimilitud, explique la intuición detrás de este y enliste algunas ventajas y desventajas de su uso.

Para cada punto  $x$  de la muestra, sea  $\hat{\theta}(x)$  el parámetro donde la función de verosimilitud  $L(\theta|x)$  alcanza un máximo.

$\hat{\theta}(\bar{x})$  es el EMV de  $\theta$  basado en una muestra  $\bar{x}$ .

- Es el parámetro más probable a ocurrir para una muestra observada.
- Es consistente, suficiente y asintóticamente convergente.
- Invariante i.e. Si  $\hat{\theta}$  es EMV de  $\theta \Rightarrow$  la función  $r(\theta)$  el EMV de  $r(\theta)$  es  $r(\hat{\theta}) \rightarrow$  Esto puede quedar como tarea.

Desventajas:

- (1) Puede ser muy difícil encontrar el máximo (en caso de que exista)
- (2) Sensibilidad Numérica. ¿Qué tan sensible es el EMV a un cambio marginal en los datos

2. Sea  $X_1, \dots, X_n$  una m.a.  $\Gamma(\alpha, \beta)$ . Encuentra el EMV si  $\alpha$  es conocido.

$$(a) L(\beta) = \prod_{i=1}^n \frac{x_i^{\alpha-1} e^{-x_i/\beta}}{\beta^\alpha \Gamma(\alpha)} = \frac{1}{\beta^{\alpha n} \Gamma(\alpha)^n} \left[ \prod_{i=1}^n x_i \right]^{\alpha-1} e^{-\sum_{i=1}^n x_i / \beta}$$

$$\ln[L(\beta)] = -n \ln[\Gamma(\alpha)] - n\alpha \ln[\beta] + (\alpha-1) \ln \left[ \prod_{i=1}^n x_i \right] - \frac{\sum_{i=1}^n x_i}{\beta}$$

$$\frac{\partial}{\partial \beta} \ln[L(\beta)] = -\frac{n\alpha}{\beta} + \frac{\sum_{i=1}^n x_i}{\beta^2} = 0 \Leftrightarrow \frac{\sum_{i=1}^n x_i}{\beta^2} = \frac{n\alpha}{\beta} \Leftrightarrow \frac{\sum_{i=1}^n x_i}{n\alpha} = \hat{\beta}_{MLE}$$

To check it's maximum

$$\frac{\partial^2}{\partial \beta^2} \ln[L(\beta)] = \frac{n\alpha}{\beta^2} - \frac{2\sum_{i=1}^n x_i}{\beta^3} \Big|_{\beta=\hat{\beta}} = \frac{(n\alpha)^3}{(\sum_{i=1}^n x_i)^2} - \frac{2(n\alpha)^3}{(\sum_{i=1}^n x_i)^2} = -\frac{(n\alpha)^3}{(\sum_{i=1}^n x_i)^2} < 0$$

✓

3. Sea  $X_1, \dots, X_n$  una m.a. con distribución  $f(x|\theta) = \theta x^{-2}$ ,  $0 < \theta \leq x < \infty$ , si  $X_{(1)}$  es un estadístico suficiente para  $\theta$ , encuentre el EMV para  $\theta$ .

(a)

$$f(\underline{x}; \theta) = \prod_{i=1}^n \theta x_i^{-2} \mathbb{1}_{(\theta, \infty)}(x_{(1)}) = \underbrace{\frac{\theta^n}{\prod_{i=1}^n x_i^2}}_{(\theta, \infty)} \underbrace{\mathbb{1}_{(\theta, \infty)}(X_{(1)})}_{g(X_{(1)}; \theta)} \sim h(x)$$

$\therefore X_{(1)}$  is a suff stat for  $\theta$   
 (Using the Factorization Theorem)

(b) From (a) we have  $L(x, \theta) = \frac{\theta^n}{\prod_{i=1}^n x_i^2} \mathbb{1}_{(\theta, \infty)}(X_{(1)}) \rightarrow \theta^n$  is increasing in  $\theta$

So, to find the MLE( $\theta$ ) we need to make  $\theta$  as large as possible

$$\Rightarrow \hat{\theta} \leq X_{(1)} \Rightarrow \hat{\theta}_{MLE} = X_{(1)}$$

(c)

$$E[x] = \int_{\theta}^{\infty} x \theta x^{-2} dx = \int_{\theta}^{\infty} \theta x^{-1} dx = \theta \ln(x) \Big|_{\theta}^{\infty} = \infty$$

$\therefore$  MME of  $\theta$  doesn't exist.

4. Sea  $X_1, \dots, X_n$  una m.a. con distribución  $f(x|\theta) = \theta x^{\theta-1}$ ,  $0 \leq x \leq 1$ ,  $0 < \theta < \infty$ . Encuentre el EMV para  $\theta$  y que pasa con la varianza si  $n \rightarrow \infty$ .

$$(1) L(\theta|x) = \prod_{i=1}^n \theta x_i^{\theta-1} = \theta^n \prod_{i=1}^n x_i^{\theta-1}$$

$$(2) l(\theta|x) = n \ln(\theta) + \sum_{i=1}^n (\theta-1) \ln(x_i)$$

$$(3) \frac{d l(\theta|x)}{d\theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln(x_i) = 0 \Leftrightarrow \frac{-n}{\sum_{i=1}^n \ln(x_i)} = \hat{\theta}$$

¿Qué SIGUE?

Vamos a ver qué pasa con la varianza

↓  
↓  
↓  
↓  
↓

¿Qué es esto?

$$\text{Sea } Y_i = -\ln x_i \Rightarrow x_i = e^{-Y_i} \therefore f_Y(y_i) = \theta [e^{-y_i}]^{\theta-1} |-e^{-y_i}| \\ = \theta e^{-y_i(\theta-1)} e^{-y_i} = \theta e^{-\theta} \therefore Y_i \sim \text{Exp}(1/\theta)$$

$$\therefore \bar{T} = -\sum_{i=1}^n \ln x_i \sim \Gamma(n, 1/\theta) \quad \leftarrow \text{Recordar } X \sim \text{Exp}(\lambda) \Rightarrow \sum_{i=1}^n X \sim \Gamma(n, \lambda)$$

$$\text{Así } \hat{\theta} = \frac{n}{\bar{T}} \quad \text{Recuerda si } K \sim \Gamma(n, 1/\theta) \Rightarrow E\left[\frac{1}{K}\right] = \frac{\theta}{n-1}$$

$$\text{Se tiene } E\{\hat{\theta}\} = E\left[\frac{n}{\bar{T}}\right] = n \cdot E\left[\frac{1}{\bar{T}}\right] = \frac{n\theta}{n-1} \quad V\left[\frac{1}{\bar{T}}\right] = \frac{\theta^2}{(n-1)^2(n-2)}$$

$$V(\hat{\theta}) = V\left[\frac{n}{\bar{T}}\right] = n^2 V\left[\frac{1}{\bar{T}}\right] = \frac{(n\theta)^2}{(n-1)^2(n-2)}$$

Finalmente

$$\lim_{n \rightarrow \infty} E\{\hat{\theta}\} = \lim_{n \rightarrow \infty} \frac{n\theta}{n-1} = \lim_{n \rightarrow \infty} \frac{\theta}{1 - \frac{1}{n}} = \theta$$

$$\lim_{n \rightarrow \infty} V(\hat{\theta}) = \lim_{n \rightarrow \infty} \frac{n^2 \theta^2}{(n-1)^2(n-2)} = \lim_{n \rightarrow \infty} \frac{\theta^2}{n \left[1 - \frac{1}{n}\right]^2 \left[1 - \frac{2}{n}\right]^2} \\ = \lim_{n \rightarrow \infty} \frac{\theta^2}{n} = 0$$

¿Qué puedes concluir de esto?

# MLE\_LAB7.R

luisgerardomartinezvaldes

2021-09-30

```
library(pacman)
p_load(data.table, fixest, lattice, magrittr, ggplot2, kableExtra)

##
## There is a binary version available but the source version is later:
##       binary source needs_compilation
## fixest  0.9.0 0.10.0          TRUE
## installing the source package 'fixest'

## Warning in utils::install.packages(package, ...): installation of package
## 'fixest' had non-zero exit status

## Warning in p_install(package, character.only = TRUE, ...):

## Warning in library(package, lib.loc = lib.loc, character.only = TRUE,
## logical.return = TRUE, : there is no package called 'fixest'

## Warning in p_load(data.table, fixest, lattice, magrittr, ggplot2, kableExtra): Failed to install/load
## fixest

#Generamos los Datos
N = 500      # Tamaño Muestra
beta = 5
sigma_2 = 5
DT <- data.table(X = rnorm(N, 0, 5),
                  U = rnorm(N, 0, sqrt(sigma_2))) %>%
  .[, Y := beta*X + U]

# Funcion de log-verosimilitud
log_like <- function(theta, Y, X){
  X <- as.matrix(X); Y <- as.matrix(Y);
  N      <- nrow(X)
  beta   <- theta[1]
  sigma_2 <- theta[2]
  e      <- Y - beta*X
  loglik <- -.5*N*log(2*pi) - .5*N*log(sigma_2) - ( (t(e) %*% e) / (2*sigma_2) )
  return(-loglik)
}

# Graficamos la funcion de verosimilitud

log_like_graf <- function(beta, sigma_2){
  X <- as.matrix(DT$X); Y <- as.matrix(DT$Y);
  N      <- nrow(X)
```


```

e      <- Y - beta*X
loglik <- -.5*N*log(2*pi) - .5*N*log(sigma_2) - ( (t(e) %*% e) / (2*sigma_2) )
return(loglik)
}
log_like_graf <- Vectorize(log_like_graf)

# Visualización de vectores en un grid
beta_vals <- seq(-10,10, by =1)
sigma2_vals <- seq(1,10, by =1)
log_vals <- outer(beta_vals, sigma2_vals, log_like_graf)

persp(beta_vals, sigma2_vals, log_vals, theta = 7, phi =8 , r= 500)

```



```

EMV_estim <- optim(fn=log_like,
                     par=c(1,1),
                     lower = c(-Inf, -Inf),
                     upper = c(Inf, Inf),
                     hessian=TRUE,
                     method = "L-BFGS-B",
                     Y = DT$Y,
                     X = DT$X)

# Funcion verosimilitud
# Suposicion inicial
# Acotar parametros inferiores
# Acotamos Parametros superiores
# Hessiano para asegurar maximo

# Examine estimates
EMV_par <- EMV_estim$par
EMV_SE <- sqrt(diag(solve(EMV_estim$hessian)))
EMV <- data.table(param = c("beta", "sigma_2"),
                   estimates = EMV_par,
                   sd = EMV_SE)

EMV

##      param   estimates      sd
## 1:    beta  5.022393 0.02066701
## 2: sigma_2  5.161654 0.32645164

```

```

kable(EMV)

\begin{table}
\begin{thead}
| param | estimates | sd |
| --- | --- | --- |
|  |  |  |
| --- | --- | --- |
| beta | 5.022393 | 0.0206670 |
| sigma_2 | 5.161654 | 0.3264516 |

\end{table}

#Graficamos los estimadores

log_like_graf_beta <- function(beta){
  sigma_2 = EMV_par[2]
  X = as.matrix(DT$X)
  Y = as.matrix(DT$Y)
  N = nrow(X)
  e = Y - beta*X
  loglik <- -.5*N*log(2*pi) - .5*N*log(sigma_2) - ( (t(e) %*% e) / (2*sigma_2) )
  return(loglik)
}

log_like_graf_sigma2 <- function(sigma_2){
  beta = EMV_par[1]
  X = as.matrix(DT$X)
  Y = as.matrix(DT$Y)
  N = nrow(X)
  e = Y - beta*X
  loglik <- -.5*N*log(2*pi) - .5*N*log(sigma_2) - ( (t(e) %*% e) / (2*sigma_2) )
  return(loglik)
}


# Vectorize
log_like_graf_beta <- Vectorize(log_like_graf_beta)
log_like_graf_sigma2 <- Vectorize(log_like_graf_sigma2)

# Grph
beta <- ggplot(data = data.frame(beta = 0), mapping = aes(beta = beta)) +
  stat_function(fun = log_like_graf_beta) +
  xlim(-40,40) + theme_bw() + xlab("beta") + ylab("log lik")


sigma2 <- ggplot(data = data.frame(sigma2 = 0), mapping = aes(sigma2 = sigma2)) +
  stat_function(fun = log_like_graf_sigma2) +
  xlim(1,20) + theme_bw() + xlab("sigma2") + ylab("log lik")

beta

```



sigma2



5. Enuncie los tipos de convergencia y explique la intuición detrás de cada una.

DEFINICIÓN. (CONVERGENCIA PUNTUAL). La sucesión de variables aleatorias  $X_1, X_2, \dots$  converge puntualmente a  $X$  si para cada  $\omega$  en  $\Omega$ ,

$$\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega).$$

DEFINICIÓN. (CONVERGENCIA CASI SEGURA). La sucesión de variables aleatorias  $X_1, X_2, \dots$  converge casi seguramente a la variable  $X$ , si

$$P\{\omega \in \Omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\} = 1.$$

DEFINICIÓN. (CONVERGENCIA EN PROBABILIDAD). La sucesión de variables aleatorias  $X_1, X_2, \dots$  converge en probabilidad a  $X$ , si para cada  $\epsilon > 0$ ,

$$\lim_{n \rightarrow \infty} P\{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \epsilon\} = 0.$$

DEFINICIÓN. (CONVERGENCIA EN MEDIA). La sucesión de variables aleatorias integrables  $X_1, X_2, \dots$  converge en media a la variable aleatoria integrable  $X$  si

$$\lim_{n \rightarrow \infty} E|X_n - X| = 0.$$

→ Existe algo como  
Convergencia en k-ésima media?

## Convergencia en distribución

Este es el tipo de convergencia menos restrictiva de todas las mencionadas. En contextos más generales se le llama también *convergencia débil*.

DEFINICIÓN. (CONVERGENCIA EN DISTRIBUCIÓN). La sucesión de variables aleatorias  $X_1, X_2, \dots$  converge en distribución a  $X$ , si para todo punto  $x$  en donde la función  $F_X(x)$  es continua, se cumple que

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x).$$

6. Demuestre que si  $X_n \xrightarrow{c.s} X$  entonces,  $aX_n + b \xrightarrow{c.s} aX + b$

Usa la definición  $X_n \xrightarrow{c.s} X \Leftrightarrow$

$$\begin{aligned} \mathbb{P}\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n = X\} &= \mathbb{P}\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} aX_n = aX\} \\ &= \mathbb{P}\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} aX_n + b = aX + b\} = 1 \end{aligned}$$

7. Sean  $X_n$  una secuencia de v.a.'s tal que  $F_{X_n} = 1 - (1 - \frac{1}{n})^{nx}$ ,  $x \geq 0$  demuestre que  $X_n \xrightarrow{d} \text{Exp}(1)$ .

Para  $x \leq 0$  tenemos  $\bar{F}_{X_n}(x) = \bar{F}_X(x) = 0 \quad \forall n \in \mathbb{N}$

$$\begin{aligned} x \geq 0 \quad \lim_{n \rightarrow \infty} \bar{F}_{X_n}(x) &= \lim_{n \rightarrow \infty} 1 - \left(1 - \frac{1}{n}\right)^{nx} \\ &= 1 - \lim_{n \rightarrow \infty} \underbrace{\left(1 - \frac{1}{n}\right)^n}_{\sum_1^n e^{-x}} = 1 - e^{-x} = \bar{F}_X(x) \sim \text{Exp}(1) \end{aligned}$$

8. Sea  $X$  una v.a. y  $X_n = X + Y_n$  donde  $\mathbb{E}(Y_n) = \frac{1}{n}$ ,  $\text{var}(Y_n) = \frac{\sigma^2}{n}$  donde  $\sigma > 0$ . Demuestre que  $X_n \xrightarrow{P} X$ .

Recordemos la desigualdad del Triángulo  $|a+b| \leq |a| + |b|$ .

Tenemos  $a = Y_n - \mathbb{E}[Y_n]$ ,  $b = \mathbb{E}[Y_n]$

$$\begin{aligned} |a+b| &= |Y_n - \mathbb{E}[Y_n] + \mathbb{E}[Y_n]| \leq |Y_n - \mathbb{E}[Y_n]| + |\mathbb{E}[Y_n]| \\ &= |Y_n - \mathbb{E}[Y_n]| + \frac{1}{n} \rightarrow \textcircled{*} \end{aligned}$$

$\forall \varepsilon > 0$  se tiene que

$$\begin{aligned} \mathbb{P}\{|X_n - X| \geq \varepsilon\} &= \mathbb{P}\{|Y_n| \geq \varepsilon\} \leq \mathbb{P}\{|Y_n - \mathbb{E}[Y_n]| + \frac{1}{n} \geq \varepsilon\} \\ &= \mathbb{P}\{|Y_n - \mathbb{E}[Y_n]| \geq \varepsilon - \frac{1}{n}\} \end{aligned}$$

Desigualdad de Chebyshov  $\rightarrow \leq \frac{\text{Var}(Y_n)}{\left(\varepsilon - \frac{1}{n}\right)^2} = \frac{\sigma^2}{n\left(\varepsilon - \frac{1}{n}\right)^2} \xrightarrow{n \rightarrow \infty} 0$

9. Sea  $X_n \sim Unif(0, \frac{1}{n})$ . Demuestre que  $X_n \xrightarrow{m^k} 0$  para todo  $r \geq 1$

$$f_{X_n}(x) = \begin{cases} n & \text{si } 0 \leq x \leq 1/n \\ 0 & \text{e.o.c.} \end{cases}$$

Recuerde  $Y \sim U(a, b)$

$$f_Y(y) = \frac{1}{b-a} \mathbb{1}_{a \leq y \leq b}$$

$$\Rightarrow \mathbb{E}[|x_n - 0|^k] = \int_0^{1/n} x^k n \, dx$$
$$= \left. \frac{n x^{k+1}}{k+1} \right|_0^{1/n} = \frac{n \left(\frac{1}{n}\right)^{k+1}}{k+1} = \frac{1}{n^k (k+1)} \xrightarrow{n \rightarrow \infty} 0$$